ACP de donnees hybrides : RS-PCA et HFV-PCA

Version de travail pour relecture

16 mars 2026

Résumé

Ce document est redige comme un mini-cours mathematique sur l'ACP de donnees hybrides (fonctionnelles + vectorielles), a partir de deux references : Ramsay & Silverman (2005) et Jang (2021). L'objectif pedagogique est de comprendre : (i) le probleme central d'optimisation, (ii) la reduction en problemes propres calculables, (iii) le role de la ponderation inter-blocs. La version presente vise une qualite "memoire/soutenance" : statut exact vs tronque explicite, hypotheses mathematiques minimales, notations homogenes et points de vigilance.

1 Introduction : le probleme mathematique a resoudre

Dans de nombreuses applications, une meme unite statistique est decrite par :

— une composante **fonctionnelle** (courbe temporelle, signal, profil),

— une composante **vectorielle** (variables cliniques, biomarqueurs, covariables usuelles).

Notons $Z_i = (Y_i, X_i)$ une observation hybride, avec $Y_i \in \mathcal{F}$ (espace fonctionnel) et $X_i \in \mathbb{R}^p$. On suppose les donnees centrees sans perte de generalite (WLOG), $\mathbb{E}[Z_i] = 0$. Le but de l'ACP hybride est de trouver des directions (ψ, θ) qui maximisent la variance projetee

$$\rho_i = \langle Z_i,\ (\psi, \theta)\rangle,$$

sous contraintes d'orthonormalite.

Le point difficile n'est pas seulement la dimension infinie de la partie fonctionnelle. C'est aussi l'heterogeneite d'echelle :

— la norme L^2 des courbes et la norme euclidienne des vecteurs ne sont pas naturellement comparables ;

— sans ponderation, un bloc peut dominer artificiellement les composantes.

1.1 Hypotheses minimales (cadre de cours)

Dans l'esprit des deux references, les ingredients minimaux sont :

— espace hilbertien separable pour la composante fonctionnelle ;

— existence des moments d'ordre 2 ;

— operateur de covariance auto-adjoint, positif et compact ;

— centrage des observations ;

— pour l'unicite des composantes : valeurs propres simples (sinon, composantes definies a rotation pres dans le sous-espace propre).

Ce document est organise comme suit :

— Section 2 : rappels PCA/FPCA ;
— Section 3 : RS-PCA (Ramsay & Silverman, chap. 10.3) ;
— Section 4 : HFV-PCA (Jang, sec. 2.2 a 2.6) ;
— Section 5 : comparaison mathematique fine.

2 Rappels mathematiques : PCA et FPCA

2.1 PCA vectorielle (dimension finie)

Soit $X \in \mathbb{R}^p$ centre, de covariance $C_X = \mathbb{E}[XX^\top]$. La premiere composante principale est solution de

$$\max_{\|w\|=1} \operatorname{Var}(w^\top X) = \max_{\|w\|=1} w^\top C_X w.$$

Par multiplicateur de Lagrange :

$$C_X w = \kappa w.$$

Les composantes suivantes ajoutent des contraintes d'orthogonalite. Les scores sont $\gamma = w^\top X$.

2.2 FPCA (dimension infinie)

Soit $Y \in L^2(\mathcal{T})$, centre, de covariance $\sigma_Y(s,t) = \operatorname{Cov}(Y(s), Y(t))$. L'operateur de covariance associe est

$$(C_Y f)(s) = \int_{\mathcal{T}} \sigma_Y(s,t) f(t)\, dt.$$

L'analogue de la PCA est

$$\max_{\|\phi\|_{L^2}=1} \operatorname{Var}\left(\int_{\mathcal{T}} Y(t)\phi(t)\, dt\right),$$

menant a

$$C_Y \phi = \tau \phi.$$

Les scores fonctionnels sont

$$\eta = \langle Y, \phi \rangle_{L^2} = \int_{\mathcal{T}} Y(t)\phi(t)\, dt.$$

La decomposition de Karhunen-Loeve tronquee :

$$Y(t) \approx \sum_{h=1}^{L} \eta_h \phi_h(t).$$

3 RS-PCA (Ramsay & Silverman)

3.1 Espace hybride et score principal

Ramsay & Silverman (chap. 10.3, eq. (10.1)-(10.4)) considerent des couples $z_i = (x_i, y_i)$, avec $x_i \in L^2(\mathcal{T})$ et $y_i \in \mathbb{R}^M$. Une direction principale hybride est $\zeta = (\xi, v)$ et le score de l'observation i est

$$\eta_i = \int x_i(s)\, \xi(s)\, ds + y_i^\top v. \tag{1}$$

Le produit scalaire hybride non pondere est

$$\langle z^{(1)}, z^{(2)} \rangle = \int x^{(1)}(s) x^{(2)}(s)\, ds + {y^{(1)}}^\top y^{(2)}. \tag{2}$$

La version ponderee est

$$\langle z^{(1)}, z^{(2)} \rangle = \int x^{(1)}(s) x^{(2)}(s)\, ds + C^2\, {y^{(1)}}^\top y^{(2)}, \tag{3}$$

ou $C > 0$ regle l'equilibre fonctionnel/vectoriel.

3.2 Probleme d'optimisation sous-jacent

Comme en PCA classique, la premiere direction hybride est solution de

$$\max_{\|\zeta\|=1} \operatorname{Var}(\langle z, \zeta \rangle),$$

et les suivantes ajoutent les contraintes d'orthogonalite pour le meme produit scalaire. Le point cle est le choix de norme (donc de ponderation).

3.3 Reduction pratique a une PCA matricielle

Dans la presentation source, la partie fonctionnelle est projetee sur une base orthonormee $\{\varphi_k\}_{k=1}^K$:

$$x_i(t) \approx \sum_{k=1}^{K} c_{ik} \varphi_k(t), \qquad c_i = (c_{i1}, \ldots, c_{iK})^\top.$$

On forme ensuite le vecteur augmente

$$w_i = (c_i,\ y_i) \quad \text{ou} \quad w_i = (c_i,\ C y_i).$$

L'eigenproblem devient celui de la covariance empirique

$$\widehat{\Sigma}_w = \frac{1}{N-1} \sum_{i=1}^{N} (w_i - \bar{w})(w_i - \bar{w})^\top. \tag{4}$$

Donc RS-PCA est une PCA standard apres encodage de la partie fonctionnelle en coefficients.

Remarque base orthonormee vs base generale Si la base n'est pas orthonormee (p. ex. splines generales), le produit scalaire entre fonctions en coefficients passe par la matrice de Gram $G_{kl} = \langle \varphi_k, \varphi_l \rangle_{L^2}$, et $\langle x_i, x_j \rangle = c_i^\top G c_j$.

3.4 Choix de ponderation discute par RS

Ramsay & Silverman discutent notamment

$$C^2 = \frac{\sum_i \|x_i - \bar{x}\|_{L^2}^2}{\sum_i \|y_i - \bar{y}\|_2^2}, \tag{5}$$

qui egalise globalement la variance des deux blocs.

3.5 Interpretation mathematique de la ponderation

Le passage de (2) a (3) est equivalent a un preconditionnement lineaire

$$y_i \mapsto C y_i, \qquad v \mapsto C^{-1} v$$

dans l'espace vectoriel. On ne change pas le principe de PCA ; on change la geometrie du probleme.

3.6 Limites discutees dans Jang (presentation neutre)

Jang (2021, introduction) souligne que cette voie *peut* etre sensible :

1. au choix du systeme de base ;
2. aux donnees fonctionnelles sparse/irregulieres (coefficients plus instables).

4 HFV-PCA (Jang, 2021)

4.1 Espace hybride et operateur de covariance

Jang (sec. 2.2, eq. (3)-(5)) construit l'espace

$$\mathcal{H} = \mathcal{F} \times \mathbb{R}^p,$$

avec produit scalaire pondere

$$\langle (f_1, v_1), (f_2, v_2) \rangle_{\mathcal{H}} = \langle f_1, f_2 \rangle_{\mathcal{F}} + \omega\, v_1^\top v_2, \tag{6}$$

ou $\omega > 0$ traite l'heterogeneite d'unites.

Pour $Z = (Y, X)$ centre, l'operateur de covariance est

$$K = \mathbb{E}\big[(Z \otimes Z)\big].$$

L'ACP hybride est la decomposition spectrale

$$K = \sum_{m \geq 1} \lambda_m\, \xi_m \otimes \xi_m, \qquad Z = \sum_{m \geq 1} \rho_m\, \xi_m, \tag{7}$$

avec scores $\rho_m = \langle Z, \xi_m \rangle_{\mathcal{H}}$.

4.2 Structure explicite de la covariance hybride

L'apport important de Jang est d'ecrire K via trois noyaux :

— covariance fonctionnelle σ_Y ;
— covariance vectorielle σ_X ;
— covariance croisee σ_{YX}.

4.3 Lien cle avec FPCA/PCA (Theoreme 4)

Jang (sec. 2.4, Theorem 4) montre qu'en tronquant FPCA et PCA a (L, J) composantes, on construit

$$V = \begin{pmatrix} V_y & V_{yx} \\ V_{xy} & V_x \end{pmatrix}, \tag{8}$$

avec

$$V_y = \mathrm{Cov}(\eta) \in \mathbb{R}^{L \times L}, \quad V_{yx} = \mathrm{Cov}(\eta, \gamma) \in \mathbb{R}^{L \times J},$$
$$V_{xy} = V_{yx}^\top \in \mathbb{R}^{J \times L}, \quad V_x = \mathrm{Cov}(\gamma) \in \mathbb{R}^{J \times J}.$$

Point de rigueur : les valeurs propres de V correspondent exactement aux valeurs propres de l'operateur *tronque*. Elles approchent les valeurs propres de l'operateur complet quand L et J augmentent (sec. 2.6).

Si $e_m = (c_m^\top, d_m^\top)^\top$ est un vecteur propre de V, alors

$$\psi_m(t) = \sum_{h=1}^{L} c_{mh}\phi_h(t), \qquad \theta_m = \sum_{j=1}^{J} d_{mj} w_j, \tag{9}$$

et le score hybride associe est

$$\rho_{im} = \sum_{h=1}^{L} c_{mh}\eta_{ih} + \sum_{j=1}^{J} d_{mj}\gamma_{ij}. \tag{10}$$

4.4 Protocole d'estimation

Pipeline pratique (Jang, sec. 2.5) :

1. estimer FPCA/MFPCA sur $\{Y_i\}$ et garder L composantes ;
2. estimer PCA sur $\{X_i\}$ et garder J composantes ;
3. former $\chi_i = (\eta_{i1}, \ldots, \eta_{iL}, \gamma_{i1}, \ldots, \gamma_{iJ})$;
4. estimer $\widehat{V}$ et diagonaliser ;
5. reconstruire (ψ_m, θ_m) et ρ_{im} par (9)-(10).

4.5 Ponderation par variance relative

Choix data-driven propose :

$$\omega = \frac{\sum_i \|Y_i - \bar{Y}\|_{\mathcal{F}}^2}{\sum_i \|X_i - \bar{X}\|_2^2}, \tag{11}$$

equivalent a $X_i \mapsto \sqrt{\omega} X_i$.

Statut de ω Ce choix est raisonnable (analogue a une standardisation inter-blocs), mais ne doit pas etre presente comme "optimal universel".

Choix pratique de L, J, M Les troncatures (L, J) puis M sont souvent choisies par PVE (pourcentage de variance expliquee), avec un compromis biais/variance.

5 Comparaison mathematique RS-PCA vs HFV-PCA

5.1 Formulation du probleme

— **Commun** : maximiser une variance projetee hybride sous contraintes d'orthonormalite.
— **Difference** : RS reduit vite a une PCA augmentee ; HFV part d'un operateur hybride et explicite le lien tronque/complet.

5.2 Lecture rapide en 5 points

— Objet : meme cible (donnees hybrides).
— Moteur : RS = PCA sur representation ; HFV = covariance hybride.
— Estimation : RS sur coefficients de base ; HFV via scores FPCA/PCA et V.
— Ponderation : C^2 (RS) et ω (HFV) jouent le meme role geometrique.
— Theorie : HFV explicite mieux statut tronque et convergence.

5.3 Intuition geometrique de la ponderation

— Sans ponderation : la direction principale suit le bloc dominant.
— Avec ponderation : on change la metrique pour comparer des variations de nature differente.
— Objectif : equilibrer l'analyse, pas imposer une egalite artificielle.

5.4 Mini-exemple jouet (K=2, p=2)

Supposons deux scores fonctionnels η_1, η_2 et deux scores vectoriels γ_1, γ_2. Alors

$$\chi = (\eta_1, \eta_2, \gamma_1, \gamma_2)^\top, \qquad V = \mathrm{Cov}(\chi) \in \mathbb{R}^{4\times 4}.$$

Si les blocs croises sont nuls, on retrouve deux ACP quasi separees. Si les blocs croises sont forts, les directions propres melangent les deux modalites : c'est exactement le but de l'ACP hybride.

6 Conclusion mathematique

Les deux methodes poursuivent la meme idee geometrique : une ACP commune sur un espace produit hybride. RS-PCA donne une route directe operationnelle. HFV-PCA formalise la covariance hybride et explicite mieux le passage du modele tronque au modele complet.

Message cle :

— sans ponderation inter-blocs, on deforme le probleme ;
— sans traitement fonctionnel adapte, on biaise la fusion.

7 Erreurs frequentes a eviter

— confondre "exact sur modele tronque" et "exact sur modele complet" ;
— oublier le centrage avant covariance/scores ;
— melanger coefficients de base (RS canonique) et scores FPCA (pipeline HFV) ;
— oublier la matrice de Gram si base non orthonormee ;
— presenter ω comme optimal universel.

8 Guide d'etude (travail personnel)

Pour consolider :

1. redemontrer la maximisation de variance en PCA ;
2. expliquer le passage FPCA infinie dimension $\to$ troncature ;
3. montrer que C^2 / ω equivaut a un rescaling ;
4. interpreter (10) comme meta-score.

9 Pistes pour la prochaine version

— ajouter une preuve guidee du Theoreme 4 ;
— ajouter un encadre "choix de troncature" ;
— integrer une version module collable dans le rapport principal.

10 Validation finale (checklist jury-ready)

OK Exactitude du statut theorique (tronque vs complet) explicitee.

OK Hypotheses minimales du cadre mathematique explicites.

OK Centrage des donnees harmonise dans tout le document.

OK Definitions de V_y, V_{yx}, V_x et dimensions ajoutees.

OK Distinction claire RS canonique vs pipeline HFV.

OK Remarque base orthonormee vs base generale (matrice de Gram).

OK Role de ω precise (data-driven, non universellement optimal).

OK Mini-exemple jouet ajoute pour lecture operationnelle.

OK Citations localisees aux sections/equations cles des sources.

OK PDF compile sans erreur ; mise en page stabilisee (hors warning systeme de cesure francaise de l'installation TeX).

References minimales

— Ramsay, J. O., & Silverman, B. W. (2005). *Functional Data Analysis* (2nd ed.), chap. 10.3 (eq. (10.1)-(10.4)).

— Jang, J. H. (2021). Principal component analysis of hybrid functional and vector data. *Statistics in Medicine*, sec. 2.2-2.6 (eq. (3)-(10), Theorem 4).