Théorie : stabilité du clustering, bootstrap et choix de k

Document de travail — projet Mars

Mars 2026

Table des matières

1 Contexte et problème

On dispose de n observations $\{x_1, \ldots, x_n\}$ et d'un algorithme de clustering $\mathcal{A}$ qui, pour un entier k, produit une partition en k clusters. Le problème central : **comment choisir** k sans vérité terrain ?

Les critères classiques (silhouette, gap statistic, Calinski-Harabasz, etc.) ont des biais connus. En particulier, les méthodes basées sur la **stabilité** (reproductibilité sous perturbation des données) peuvent biaiser vers $k = 2$: moins de clusters $\Rightarrow$ partitions plus stables mécaniquement.

Ce document expose la théorie derrière quatre approches de la littérature et leur lien avec notre protocole actuel.

2 Notre protocole actuel (maximisation de l'ARI)

2.1 Algorithme

Pour chaque triplet (k, α, ω) :

1. Calculer la partition $\mathcal{C}$ sur les n individus (PAM avec $D_w(\alpha, \omega)$).
2. Répéter B fois :
   — Sous-échantillonner 80% des individus (sans remise) $\rightarrow$ ensemble I_b.
   — Calculer $\mathcal{C}_b^* = \text{PAM}$ sur I_b.
   — $\text{ARI}_b = \text{ARI}(\mathcal{C}_{|I_b}, \mathcal{C}_b^*)$ (restriction de $\mathcal{C}$ aux individus de I_b).
3. Stabilité : $\text{Stab}(k, \alpha, \omega) = \frac{1}{B} \sum_{b=1}^{B} \text{ARI}_b$.

On retient le triplet qui **maximise** Stab.

2.2 Problème identifié

Avec $k = 2$, il n'y a que deux clusters. La comparaison ARI entre $\mathcal{C}$ et $\mathcal{C}_b^*$ porte sur deux partitions binaires : les désaccords sont structurellement limités. Avec $k = 4$, quatre clusters peuvent se réarranger de bien plus de façons sous un sous-échantillonnage $\Rightarrow$ ARI plus bas en moyenne.

Conséquence : $\text{Stab}(k = 2) \geq \text{Stab}(k = 4)$ même quand la vraie structure a 4 classes. Biais systématique vers les petits k.

3 Clest (Dudoit & Fridlyand, 2002)

3.1 Idée centrale

Clest repose sur la **prédictibilité** des affectations de clusters : si la structure est réelle, un classifieur entraîné sur un sous-ensemble doit prédire correctement les labels obtenus par clustering sur un autre sous-ensemble.

On ne compare pas directement deux partitions ; on compare *prédiction* vs *clustering* sur un même ensemble test.

3.2 Procédure détaillée

Pour chaque $k \in \{2, \ldots, M\}$:
Étape 1 (répétée B fois) :

1. Diviser $\mathcal{L}$ en learning $\mathcal{L}_b$ et test $\mathcal{T}_b$ (non chevauchants).
2. Clustering sur $\mathcal{L}_b \rightarrow$ partition $\mathcal{C}(\cdot; \mathcal{L}_b)$.
3. Construire un classifieur $C(\cdot; \mathcal{L}_b)$ à partir de $\mathcal{L}_b$ et de ses labels de cluster.

4. Appliquer C sur $\mathcal{T}_b \to$ labels prédits $\hat{Y}$.
5. Appliquer le clustering sur $\mathcal{T}_b \to$ partition $\mathcal{C}(\cdot; \mathcal{T}_b)$.
6. Calculer un indice de similarité $s_{k,b}$ entre $\hat{Y}$ et $\mathcal{C}(\cdot; \mathcal{T}_b)$ sur $\mathcal{T}_b$ (ex. Fowlkes-Mallows, Rand ajusté).

Étape 2 : $t_k = \text{mediane}(s_{k,1}, \ldots, s_{k,B})$.

Étape 3 : Générer B_0 jeux de données sous l'hypothèse nulle $H_0 : K = 1$ (ex. uniforme sur l'enveloppe des données). Pour chacun, répéter les étapes 1–2 $\to t^0_{k,1}, \ldots, t^0_{k,B_0}$.

Étape 4 :

$$\bar{t}^0_k = \frac{1}{B_0} \sum_{b=1}^{B_0} t^0_{k,b}, \quad d_k = t_k - \bar{t}^0_k, \quad p_k = \frac{1}{B_0} \#\{b : t^0_{k,b} \geq t_k\}.$$

Sélection :

$$\mathcal{K}^- = \{k : p_k \leq p_{\max},\ d_k \geq d_{\min}\}, \quad \hat{K} = \begin{cases} 1 & \text{si } \mathcal{K}^- = \emptyset \\ {}_{k \in \mathcal{K}^-} d_k & \text{sinon} \end{cases}$$

Paramètres typiques : $p_{\max} = 0.05$, $d_{\min} = 0.05$.

3.3 Calibration par la nullité

La clé de Clest : on ne compare pas t_k entre différents k directement. On compare t_k à son espérance sous H_0 (pas de clusters). Un k avec des clusters artificiels aura $t_k \approx \bar{t}^0_k$. Un k avec une structure réelle aura $t_k \gg \bar{t}^0_k \Rightarrow d_k$ grand.

Cela évite le biais « plus de clusters = plus instable » car la calibration est faite *par* k via la référence nulle.

3.4 Classifieur utilisé

Dans l'article : DLDA (Diagonal Linear Discriminant Analysis), i.e. règle de Bayes avec covariances diagonales et égales. Pour PAM sur distances : on peut utiliser l'affectation au médoïde le plus proche comme « classifieur ».

4 Bagging (Dudoit & Fridlyand, 2003)

4.1 Objectif

Le bagging en clustering ne vise pas à choisir k, mais à **améliorer** et **évaluer** la précision d'une procédure de clustering donnée (avec k fixé).

4.2 Principe

L'instabilité des algorithmes de clustering (petite perturbation $\Rightarrow$ grande variation des résultats) est exploitée positivement :

1. Générer B échantillons bootstrap (tirages avec remise de taille n).
2. Sur chaque échantillon, obtenir une partition.
3. Agréger les partitions (ex. vote majoritaire pour chaque paire d'observations, ou consensus par matrice de co-association).

4.3 Lien avec notre protocole

Notre sous-échantillonnage à 80% *sans* remise est différent du bootstrap classique (avec remise). Le bootstrap à 80% sans remise correspond à une « sous-échantillonnage aléatoire » ; la fraction attendue d'individus dans un bootstrap est $\approx 1 - e^{-1} \approx 63\%$.

Notre approche mesure la stabilité (ARI moyen) plutôt que d'agréger les partitions. Le lien conceptuel : les deux exploitent la variabilité des partitions sous resampling.

5 Wang (2010) : instabilité et validation croisée

5.1 Définition de l'instabilité

Soit $\mathcal{A}$ un algorithme de clustering. Pour un k fixé, l'**instabilité** est :

$$\mathrm{Inst}(k) = \mathbb{E}\left[\mathrm{disaccord}(\mathcal{A}(\mathcal{L}_1, k), \mathcal{A}(\mathcal{L}_2, k))\right]$$

où $\mathcal{L}_1, \mathcal{L}_2$ sont deux échantillons indépendants de même loi que les données, et « disaccord » mesure la dissimilarité entre les deux partitions (sur l'intersection ou sur une population de référence).

5.2 Critère de sélection

Wang propose de choisir $\hat{k}$ qui **minimise** l'instabilité estimée :

$$\hat{k} =_k \widehat{\mathrm{Inst}}(k).$$

5.3 Estimation par validation croisée

1. Diviser les données en V plis (ex. $V = 2$).
2. Pour chaque paire de plis $(\mathcal{L}_1, \mathcal{L}_2)$:
   — Clustérer $\mathcal{L}_1$ et $\mathcal{L}_2$ séparément.
   — Pour classer les points de $\mathcal{L}_2$ selon les clusters de $\mathcal{L}_1$: affecter au cluster le plus proche (médoïde, centroid, etc.).
   — Mesurer le désaccord entre cette affectation et le clustering natif de $\mathcal{L}_2$.
3. Moyenner sur les paires $\to \widehat{\mathrm{Inst}}(k)$.

5.4 Consistance

Sous des conditions de régularité, Wang établit la **consistance** du critère : $\hat{k} \to K_0$ en probabilité quand $n \to \infty$, où K_0 est le « vrai » nombre de clusters.

6 Fang & Wang (2012) : bootstrap

6.1 Idée

Même critère que Wang (minimiser l'instabilité), mais l'estimation se fait par **bootstrap** au lieu de la validation croisée.

6.2 Procédure

Pour chaque k :

1. Répéter B fois :
   — Tirer deux échantillons bootstrap $\mathcal{B}_1, \mathcal{B}_2$ (avec remise, taille n).
   — Clustérer $\mathcal{B}_1$ et $\mathcal{B}_2$ avec k clusters.

— Les points de $\mathcal{B}_2$ peuvent ne pas être dans $\mathcal{B}_1$: il faut les *classifier* dans les clusters de $\mathcal{B}_1$ (ex. affectation au centroid/médoïde le plus proche).
— Calculer une mesure de désaccord entre les deux partitions (sur les points communs ou via la classification).

2. $\widehat{\text{Inst}}(k) = \frac{1}{B}\sum_{b=1}^{B} \text{disaccord}_b$.

$\hat{k} =_k \widehat{\text{Inst}}(k)$.

6.3 Différence avec notre protocole

	Notre protocole	Fang-Wang
Critère	Maximiser ARI (stabilité)	Minimiser instabilité
Référence	Partition complète $\mathcal{C}$	Paires de bootstrap
Comparaison	$\mathcal{C}_{\mid I_b}$ vs $\mathcal{C}_b^*$	$\mathcal{C}_1$ vs $\mathcal{C}_2$ (après classification)
Biais k	Favorise petits k	Calibration différente

Dans Fang-Wang, les deux partitions sont sur des échantillons *indépendants* (bootstrap). Le désaccord est mesuré de façon symétrique. Il n'y a pas de partition « de référence » fixe, ce qui peut réduire le biais vers $k = 2$.

6.4 Implémentation R

La fonction `nselectboot` du package `fpc` implémente cette approche. Elle accepte des matrices de distances (`dist`) et des méthodes comme `claraCBI` (PAM) ou `disthclustCBI` (clustering hiérarchique).

7 clusterboot (fpc) : stabilité par Jaccard

7.1 Méthode

`clusterboot` évalue la stabilité de chaque *cluster* individuellement :

1. Clustérer les données $\rightarrow$ clusters $C_1, \ldots, C_k$.
2. Répéter B fois : bootstrap (ou subset), reclustérer.
3. Pour chaque cluster C_i de la partition initiale, calculer le coefficient de Jaccard avec le cluster le plus similaire dans chaque partition bootstrap.
4. Stabilité du cluster i = moyenne des Jaccards.

Un cluster est considéré « dissous » si son Jaccard max tombe sous 0.5.

7.2 Différence avec ARI

L'ARI compare deux *partitions* globales. Le Jaccard cluster-wise compare chaque cluster à son meilleur correspondant. Les deux peuvent réagir différemment au choix de k.

8 Synthèse et recommandations

8.1 Comparaison des approches

1. **Clest** : Calibration par nullité. Peut mieux discriminer les vrais k car d_k est comparé à $E[t_k|H_0]$. Coût : nécessite génération de données sous H_0 et un classifieur.
2. **Fang-Wang (nselectboot)** : Minimise l'instabilité. Pas de partition de référence fixe. Implémentation directe dans `fpc`.

3. **Wang (CV)** : Similaire à Fang-Wang, avec CV au lieu du bootstrap. Consistance théorique.
4. **Notre protocole** : Simple, mais biais vers $k = 2$ car ARI entre partition complète et bootstrap favorise les petits k.

8.2 Pistes pour notre expérience

1. Tester `nselectboot` avec `claraCBI` sur nos matrices $D_w(\alpha, \omega)$ pour une grille de (α, ω) fixés (ex. meilleur couple actuel).
2. Implémenter une variante Clest : split train/test, PAM sur train, affectation au médoïde le plus proche sur test, indice FM entre prédiction et clustering test.
3. Comparer le k sélectionné par chaque méthode sur nos 4 datasets.
4. Envisager un **vote** entre critères (stabilité ARI, nselectboot, silhouette, gap) pour le choix de k.

9 Références bibliographiques

1. Dudoit, S., Fridlyand, J. (2002). A prediction-based resampling method for estimating the number of clusters in a dataset. *Genome Biology*, 3(7), research0036.
2. Dudoit, S., Fridlyand, J. (2003). Bagging to improve the accuracy of a clustering procedure. *Bioinformatics*, 19(9), 1090–1099.
3. Wang, J. (2010). Consistent selection of the number of clusters via crossvalidation. *Biometrika*, 97(4), 893–904.
4. Fang, Y., Wang, J. (2012). Selection of the number of clusters via the bootstrap method. *Computational Statistics and Data Analysis*, 56(3), 468–477.
5. Hennig, C. (2007). Cluster-wise assessment of cluster stability. *Computational Statistics and Data Analysis*, 52(1), 258–271. (clusterboot)