Expérience 01 — Instabilité bootstrap et choix de k (Fang & Wang)

Pierre Chambet

Mars 2026

Résumé

On veut choisir k (nombre de clusters) et les paramètres de distance (α, ω) sans labels. Ce rapport se concentre sur une méthode de la littérature : **nselectboot** (Fang & Wang, 2012), implémentée dans R (`fpc::nselectboot`), qui minimise une **instabilité** mesurée par bootstrap. Un ancien protocole de « stabilité » ad hoc (sans article de référence) a été retiré pour clarifier le message. On teste une grille 21×21 en (α, ω) sur quatre jeux de données ; les labels ne servent qu'à évaluer l'ARI une fois k choisi. Un **volet simulé** (données hybrides Cas2_deriv, aligné sur l'expérience 03) complète l'étude sous vérité de k connue ; il ne remplace pas l'évaluation sur données réelles.

Table des matières

1 Objectif de l'expérience 1 **2**

2 Le problème en une phrase **2**

3 Les trois paramètres et les données **2**

4 nselectboot (Fang & Wang, 2012) **2**
- 4.1 Idée . . . 2
- 4.2 PAM . . . 2
- 4.3 Protocole (résumé) . . . 2
- 4.4 Résumé sur la grille . . . 3

5 Résultats : triplets retenus pour l'évaluation (nselectboot) **3**

6 Matrices de confusion (nselectboot) **3**

7 Heatmaps d'instabilité (nselectboot) **4**
- 7.1 Canadian . . . 4
- 7.2 AEMET . . . 5
- 7.3 Growth . . . 5
- 7.4 Tecator . . . 6

8 Volet simulé (complément contrôlé) **6**

9 Paramètres des expériences **6**

10 Conclusion **7**

1 Objectif de l'expérience 1

On veut choisir trois quantités **sans utiliser les labels pour le choix** :
— k : nombre de clusters.
— α : pondération entre distance sur les courbes (niveau) et sur les dérivées (forme).
— ω : pondération entre partie fonctionnelle et partie vectorielle (Z).

La méthode retenue est **nselectboot** : pour chaque couple (α, ω) de la grille, on estime un k_{opt} qui minimise l'instabilité bootstrap. On obtient une carte $(\alpha, \omega) \mapsto k_{\text{opt}}$ et des heatmaps d'instabilité par k.

Pourquoi une grille en (α, ω) ? Parce que α et ω changent la matrice de distances $D_w(\alpha, \omega)$ et donc le clustering. Les heatmaps montrent l'instabilité par (α, ω) et k : **bleu = faible instabilité (bon)**, **rouge = forte (mauvais)**.

2 Le problème en une phrase

Pour du clustering, il faut fixer k et la distance. Sans vérité terrain pour choisir, on utilise un critère documenté (instabilité bootstrap).

3 Les trois paramètres et les données

— k : nombre de clusters testé dans $\{2, \ldots, 6\}$.
— α : mélange D_0 (courbes) / D_1 (dérivées).
— ω : mélange distance fonctionnelle / distance sur Z.

Quatre jeux de données (labels uniquement pour **évaluer** après coup) : Canadian, AEMET, Growth, Tecator. Les k_{vrai} utilisés dans les tableaux viennent des scripts `src/00_preprocess*.R` : Canadian (`CanadianWeather$region`), Growth (garçons/filles), AEMET et Tecator via des règles définies dans le projet (géographie / seuils sur la matière grasse) — ce ne sont pas des vérités « absolues », mais des références pour comparer les partitions.

4 nselectboot (Fang & Wang, 2012)

4.1 Idée

On **minimise l'instabilité** : à chaque répétition bootstrap, on mesure à quel point deux partitions (obtenues sur deux échantillons bootstrap) se contredisent. Le k qui minimise cette instabilité moyenne est retenu pour le couple (α, ω) fixé.

4.2 PAM

PAM (k-medoids) travaille sur une matrice de distances ; les centres sont des **médoïdes** (individus réels), ce qui limite l'influence des outliers par rapport à des moyennes (k-means).

4.3 Protocole (résumé)

Pour chaque (α, ω) de la grille (21×21, pas 0.05), avec $B = 150$:

1. Construire $D_w(\alpha, \omega)$ (même pipeline que le reste du projet : lissage, FPCA, distances).
2. Pour chaque $k \in \{2, \ldots, 6\}$, `fpc::nselectboot` tire deux échantillons bootstrap d'indices, clusterise avec PAM sur les sous-matrices, complète les partitions sur tous les individus (classification croisée), puis agrège une mesure d'instabilité (voir code du package).
3. $k_{\text{opt}} = \arg\min_k \widehat{\text{instabilité}}(k)$.

Les fichiers `nselectboot_*.csv` et les figures `nselectboot_heatmap_*.png` synthétisent les résultats.

4.4 Résumé sur la grille

En regardant la médiane des k_{opt} sur les 441 couples : Canadian $\to$ 4, AEMET $\to$ 4, Growth $\to$ 2, Tecator $\to$ 3, cohérent avec les k_{vrai} retenus pour l'évaluation (sauf conventions sur AEMET/Tecator).

5 Résultats : triplets retenus pour l'évaluation (nselectboot)

Pour les matrices de confusion, on prend le premier couple (α, ω) de la grille tel que $k_{\text{opt}} = k_{\text{vrai}}$ (sinon le plus proche), comme dans `generate_confusion_nselectboot.R`.

Dataset	k_{vrai}	k	(α, ω)	ARI
Canadian	4	4	$(0.25, 0.15)$	0.62
AEMET	4	4	$(0.35, 0.20)$	0.39
Growth	2	2	$(0.10, 0.05)$	0.42
Tecator	3	3	$(0.75, 0.10)$	0.58

TABLE 1 – Partition évaluée avec les labels (ARI).

6 Matrices de confusion (nselectboot)

Lignes = vraies classes. Colonnes = clusters prédits.

Canadian ($k = 4$, ARI 0.62)

	C1	C2	C3	C4
Arctic	0	0	3	0
Atlantic	15	0	0	0
Continental	1	6	5	0
Pacific	0	4	0	1

AEMET ($k = 4$, ARI 0.39)

	C1	C2	C3	C4
Atlantique	9	4	0	0
Continental	2	19	0	0
Mediterranee	0	3	15	0
Sud	0	3	10	8

Growth ($k = 2$, ARI 0.42)

	C1	C2
Fille	6	48
Garcon	29	10

Tecator ($k = 3$, ARI 0.58)

	C1	C2	C3
Maigre	19	0	93
Moyen	39	23	0
Gras	2	39	0

7 Heatmaps d'instabilité (nselectboot)

Pour chaque k, l'instabilité en fonction de (α, ω). Bleu = bas = bon. $\times$ = meilleur (α, ω) pour ce k (voir script d'analyse).

7.1 Canadian

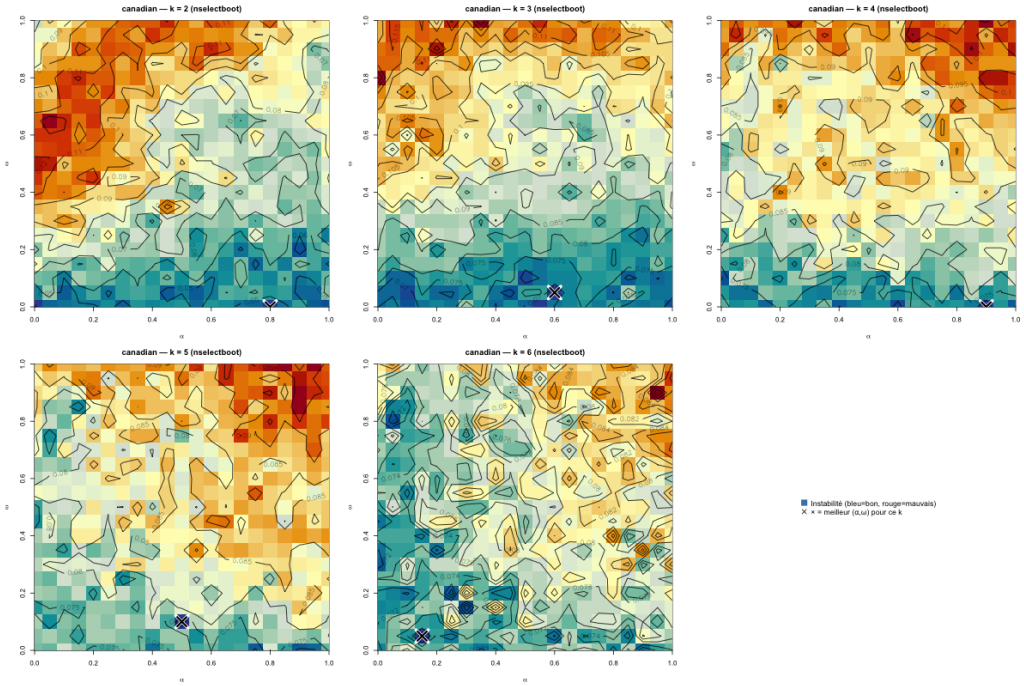

7.2 AEMET

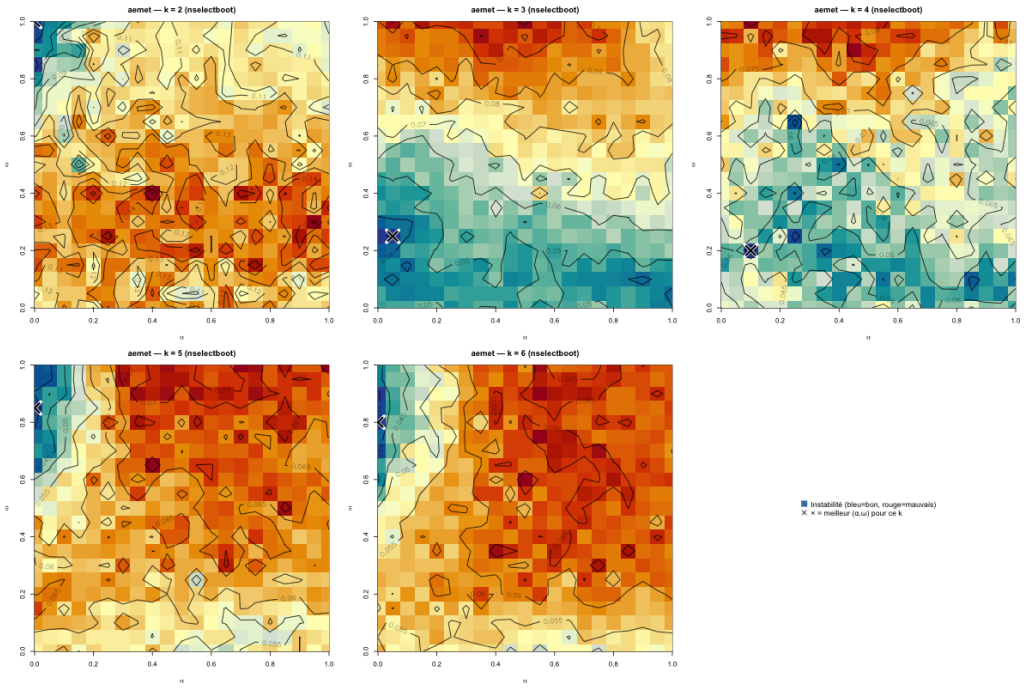

7.3 Growth

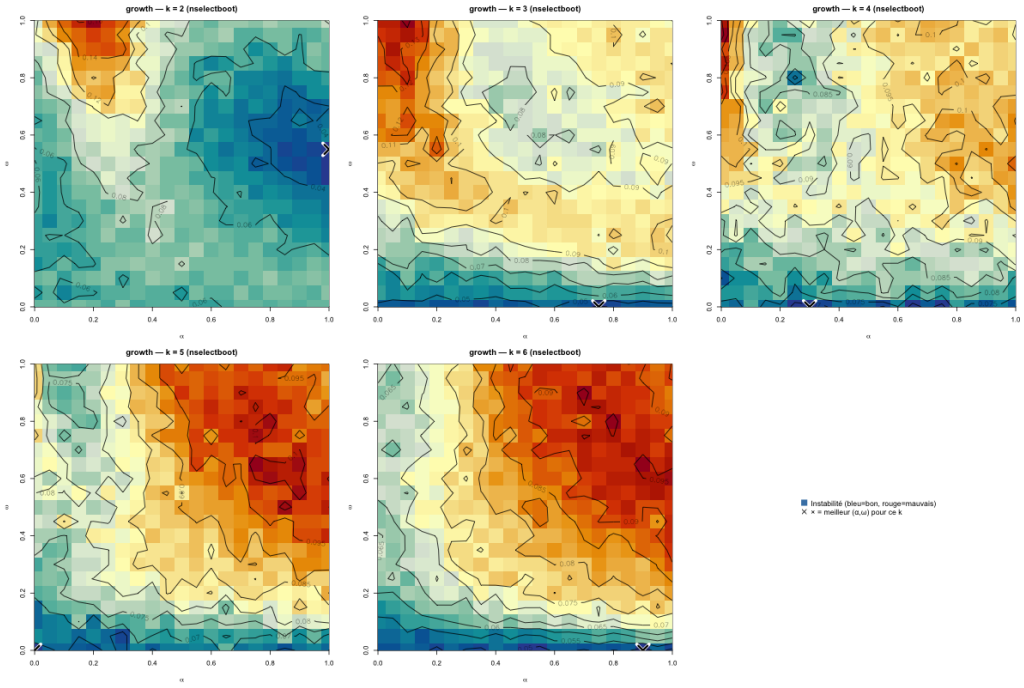

7.4 Tecator

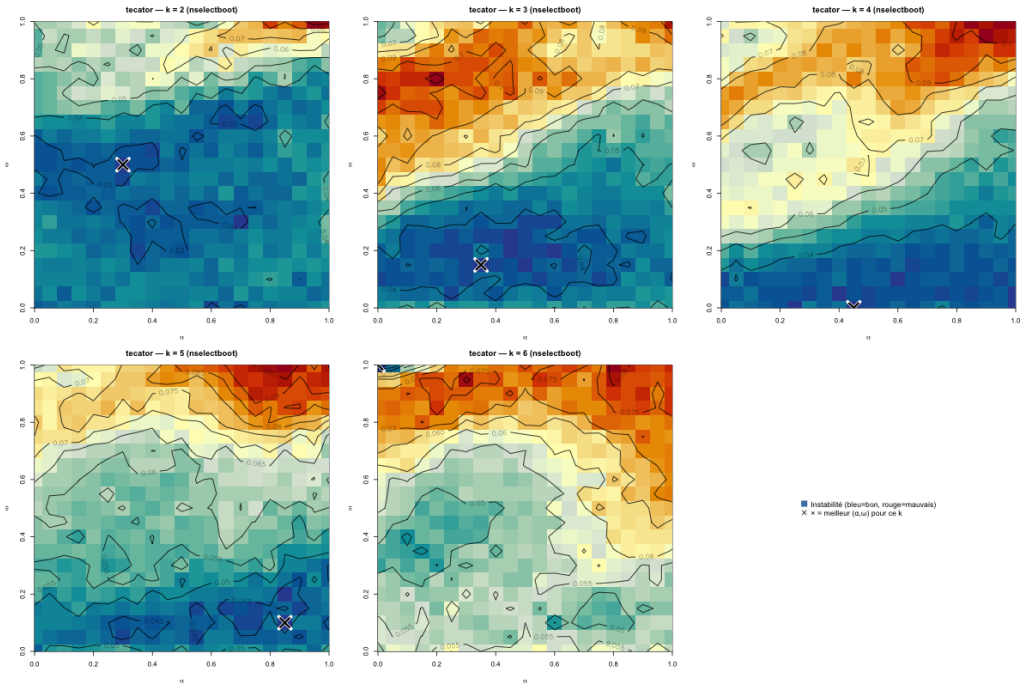

8 Volet simulé (complément contrôlé)

On enrichit l'expérience 1 avec le **même** protocole nselectboot appliqué aux **données simulées** du projet (Cas2_deriv, scénarios S1–S4 comme l'expérience 03). Ici k_{vrai} et les labels sont fournis par le générateur : l'intérêt est de **valider le pipeline** sous hypothèses contrôlées, pas de conclure sur le monde réel sans les quatre jeux ci-dessus.

Risques et limites.

- Le générateur impose une structure de covariance et un couplage fonctionnel / vectoriel qui ne coïncident pas nécessairement avec les données réelles.
- Un nombre de seeds et de scénarios suffisant doit être documenté pour éviter tout cherry-picking (voir `results_simulated/README.md`).
- Ce volet est explicitement **complémentaire** : les tableaux et heatmaps sur Canadian, AEMET, Growth et Tecator restent la référence empirique principale.

Exemple de heatmap (scénario S1, seed de référence).

(Figure absente : exécuter `analyse_nselectboot_simulated.R` après `run_nselectboot_simulated.R`.)

9 Paramètres des expériences

- Grille $\alpha, \omega \in \{0, 0.05, \ldots, 1\}$ (21×21).
- $k \in \{2, \ldots, 6\}$, $B = 150$ répétitions bootstrap pour nselectboot.
- Même prétraitement que le pipeline principal (`src/01_lissage.R`, `02_fpca.R`, `03_distances.R`).
- **Simulé :** `src/00_preprocess_simulated.R`, scénarios S1–S4 et paramètres alignés sur l'expérience 03 ; sorties `experiments/01_stabilite/results_simulated/`.

10 Conclusion

L'expérience 1 s'appuie sur une méthode publiée (instabilité bootstrap, Fang & Wang) pour choisir k à (α, ω) fixé, puis explore toute la grille. Les labels servent uniquement à l'ARI et aux matrices de confusion, pas au choix de (k, α, ω). Le volet simulé ajoute une validation sous modèle sans se substituer aux résultats sur les quatre jeux réels.

Références :

— Fang, Y., Wang, J. (2012). Selection of the number of clusters via the bootstrap method. *Computational Statistics and Data Analysis*, 56(3), 468–477.