Expérience 01 — Comment choisir le nombre de clusters et les paramètres ?

Pierre Chambet

Mars 2026

Résumé

On a trois paramètres à choisir : k (nombre de groupes), α et ω (qui règlent la distance). On compare deux méthodes : la stabilité (notre protocole) et nselectboot (méthode de la littérature). La stabilité choisit toujours $k = 2$, ce qui pose problème. nselectboot donne des résultats plus variés et récupère $k = 4$ sur Canadian et AEMET, et $k = 3$ sur Tecator.

Table des matières

1 Le problème en une phrase **3**

2 Les trois paramètres à choisir **3**

3 Méthode 1 : La stabilité (notre protocole) **3**
3.1 L'idée . . . 3
3.2 Comment on fait . . . 3
3.3 PAM et ARI en bref . . . 3
3.4 Résultat . . . 3

4 Méthode 2 : nselectboot (Fang & Wang, 2012) **3**
4.1 L'idée . . . 3
4.2 Comment on fait . . . 4
4.3 Résultat . . . 4

5 Comparaison des deux méthodes **4**
5.1 Ce qu'on observe . . . 4

6 Pourquoi la stabilité favorise $k = 2$? **4**

7 Heatmaps et matrices de confusion : deux protocoles, deux résultats **4**
7.1 Matrices de confusion : comparaison côte à côte . . . 5

8 Sensibilité au nombre de répétitions B **5**

9 Autres méthodes de la littérature **5**

10 Pistes pour la suite **5**

11 Heatmaps : stabilité vs nselectboot **6**
11.1 Stabilité (notre protocole) . . . 6
11.2 nselectboot . . . 6
11.3 Canadian — Stabilité . . . 6

11.4 Canadian — nselectboot 7
11.5 Autres datasets 7

12 Paramètres des expériences **7**

13 Conclusion **7**

1 Le problème en une phrase

Pour faire du clustering, il faut choisir : combien de groupes (k) ? Et quels paramètres pour la distance (α, ω) ? On n'a pas de labels pour vérifier. Il faut donc des critères qui marchent sans vérité terrain.

2 Les trois paramètres à choisir

- k : nombre de clusters. Exemple : 2 groupes, 3 groupes, etc.
- α : mélange entre distance sur les courbes (niveau) et sur les dérivées (forme). 0 = niveau seul, 1 = forme seule.
- ω : mélange entre partie fonctionnelle (courbes) et partie vectorielle (latitude, altitude, etc.). 0 = vectoriel seul, 1 = fonctionnel seul.

On teste une grille : k de 2 à 6, α et ω de 0 à 1. On a 4 jeux de données avec des labels (pour évaluer) : Canadian (35 stations, 4 régions), AEMET (73 stations, 4 zones), Growth (93 enfants, 2 sexes), Tecator (215 échantillons, 3 niveaux de gras).

3 Méthode 1 : La stabilité (notre protocole)

3.1 L'idée

Un bon choix de paramètres donne des groupes **reproductibles** : si on enlève quelques individus au hasard et qu'on reclustère, on doit retrouver à peu près les mêmes groupes.

3.2 Comment on fait

Pour chaque triplet (k, α, ω) :

1. On fait PAM sur tous les n individus $\rightarrow$ partition $\mathcal{C}$.
2. On répète 150 fois : on garde 80 % des individus au hasard, on reclustère dessus $\rightarrow$ partition $\mathcal{C}_b^*$. On compare $\mathcal{C}$ et $\mathcal{C}_b^*$ avec l'ARI (accord entre les deux).
3. Stabilité = moyenne des 150 ARI.

On garde le triplet avec la stabilité la plus haute.

3.3 PAM et ARI en bref

PAM : comme k-means, mais les centres sont de vrais individus (médoïdes). Ça marche avec n'importe quelle distance.

ARI : mesure l'accord entre deux partitions. Entre -1 et 1. ARI = 1 = tout pareil. On compare toujours sur les mêmes individus (les 80 % gardés).

3.4 Résultat

La stabilité choisit **toujours** $k = 2$, quel que soit le dataset. Sur Canadian et AEMET, il y a pourtant 4 classes. On perd de l'information.

4 Méthode 2 : nselectboot (Fang & Wang, 2012)

4.1 L'idée

Cette méthode **minimise l'instabilité** au lieu de maximiser la stabilité. L'instabilité mesure : à quel point les clusters changent quand on refait un tirage bootstrap. Moins ça change, mieux c'est.

4.2 Comment on fait

On teste plusieurs couples (α, ω). Pour chaque couple, on tire des paires d'échantillons bootstrap, on clustère chacun, on mesure le désaccord. Le k qui minimise ce désaccord est retenu. Implémentation : fonction `nselectboot` du package R `fpc`.

4.3 Résultat

Le k optimal **change** selon (α, ω). Sur une grille 21×21 (441 couples), on obtient des k différents selon les zones. En prenant la médiane sur la grille : Canadian → 4, AEMET → 4, Growth → 2, Tecator → 3. Pour Canadian, AEMET et Tecator, c'est le bon k.

5 Comparaison des deux méthodes

Dataset	k_{vrai}	**Stabilité**		**nselectboot**	
		k, (α, ω)	ARI	k, (α, ω)	ARI
Canadian	4	2, (0.30, 0)	0.54	4, (0.25, 0.15)	0.62
AEMET	4	2, (0, 1)	0.27	4, (0.35, 0.20)	0.39
Growth	2	2, (1, 0.45)	0.72	2, (0.10, 0.05)	0.42
Tecator	3	2, (0.40, 0.30)	0.47	3, (0.75, 0.10)	0.58

TABLE 1 – Comparaison : chaque méthode choisit un triplet différent. L'ARI est calculé sur la partition obtenue avec ce triplet.

5.1 Ce qu'on observe

- **Growth** : les deux méthodes trouvent $k = 2$. C'est correct. ARI = 0.72, bon résultat.
- **Canadian et AEMET** : la stabilité dit $k = 2$, nselectboot dit $k = 4$ (médiane sur la grille). Le vrai k est 4. nselectboot fait mieux ici.
- **Tecator** : la stabilité dit $k = 2$, nselectboot trouve $k = 3$ (le vrai k). Avec la grille fine, nselectboot récupère les 3 classes.

6 Pourquoi la stabilité favorise $k = 2$?

Avec $k = 2$, on a deux groupes. Deux partitions à deux groupes ont peu de façons de diverger : soit on est d'accord, soit on sépare différemment. Avec $k = 4$, quatre groupes peuvent se réarranger de plein de façons. Donc l'ARI entre la partition complète et celle du sous-échantillon est plus bas en moyenne. La stabilité favorise mécaniquement les petits k.

7 Heatmaps et matrices de confusion : deux protocoles, deux résultats

Important : les heatmaps et les matrices de confusion **dépendent du protocole**. Ce n'est pas la même chose.

- **Heatmaps stabilité** : montrent la stabilité (moyenne ARI) pour chaque (α, ω) et chaque k. Données : `stabilite_*.csv`.
- **Heatmaps nselectboot** : montrent l'instabilité pour chaque (α, ω) et chaque k. Bleu = instabilité faible (bon), rouge = forte (mauvais). Données : `nselectboot_*.csv`.

— **Matrices de confusion** : une par méthode, car chaque méthode choisit un triplet (k, α, ω) différent $\rightarrow$ partition différente.

7.1 Matrices de confusion : comparaison côte à côte

Lignes = vraies classes. Colonnes = clusters trouvés.

Canadian. Stabilité : $k = 2$, 4 régions en 2 clusters. nselectboot : $k = 4$, les 4 régions sont séparées. ARI passe de 0.54 à 0.62.

Stabilité ($k = 2$, ARI 0.54)

	C1	C2
Arctic	0	3
Atlantic	15	0
Continental	1	11
Pacific	1	4

nselectboot ($k = 4$, ARI 0.62)

	C1	C2	C3	C4
Arctic	0	0	3	0
Atlantic	15	0	0	0
Continental	1	6	5	0
Pacific	0	4	0	1

AEMET. Stabilité : $k = 2$, ARI 0.27. nselectboot : $k = 4$, ARI 0.39. Les 4 zones sont mieux séparées avec nselectboot.

Growth. Les deux ont $k = 2$. Stabilité : ARI 0.72 (meilleur (α, ω)). nselectboot : ARI 0.42. Ici la stabilité fait mieux car elle a choisi un meilleur couple (α, ω).

Tecator. Stabilité : $k = 2$, ARI 0.47. nselectboot : $k = 3$ (le vrai k), ARI 0.58. Avec la grille fine, nselectboot récupère les 3 classes.

8 Sensibilité au nombre de répétitions B

On a testé $B = 50, 55, 70, 150$. Le triplet optimal change un peu selon B, surtout pour Canadian. Avec $B = 150$ et la grille fine, on converge vers $k = 2$ partout. Augmenter B ne corrige pas le biais vers $k = 2$.

9 Autres méthodes de la littérature

— **Clest** (Dudoit & Fridlyand, 2002) : split train/test, on clustère le train, on prédit sur le test. On compare à des données sans structure (H_0). Sans cette calibration, notre prototype donne aussi $k = 2$.

— **Wang (2010)** : validation croisée pour estimer l'instabilité. Même idée que Fang-Wang, avec une autre façon de tirer les échantillons.

Références en fin de rapport.

10 Pistes pour la suite

1. **Coupler les méthodes** : utiliser la stabilité pour (α, ω) et nselectboot pour k.
2. **Vote** : faire voter plusieurs critères (stabilité, nselectboot, silhouette, gap) et prendre le choix majoritaire.
3. **Calibration H_0 pour Clest** : implémenter la partie « données sans structure » pour voir si Clest fait mieux.

11 Heatmaps : stabilité vs nselectboot

Deux types de heatmaps, car les deux protocoles produisent des grilles différentes.

11.1 Stabilité (notre protocole)

Pour chaque k, la stabilité (moyenne ARI) en fonction de (α, ω). Rouge = haut = bon. $\times$ = meilleur (α, ω) pour ce k.

11.2 nselectboot

Pour chaque k, l'instabilité en fonction de (α, ω). Bleu = bas = bon (peu instable). $\times$ = meilleur (α, ω) pour ce k.

11.3 Canadian — Stabilité

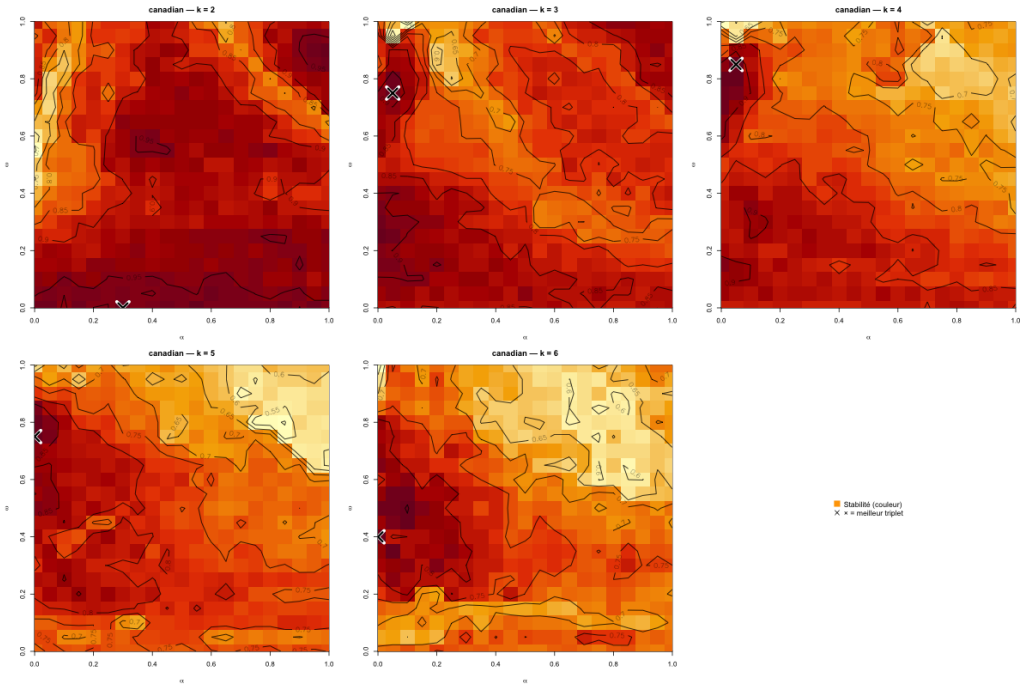

11.4 Canadian — nselectboot

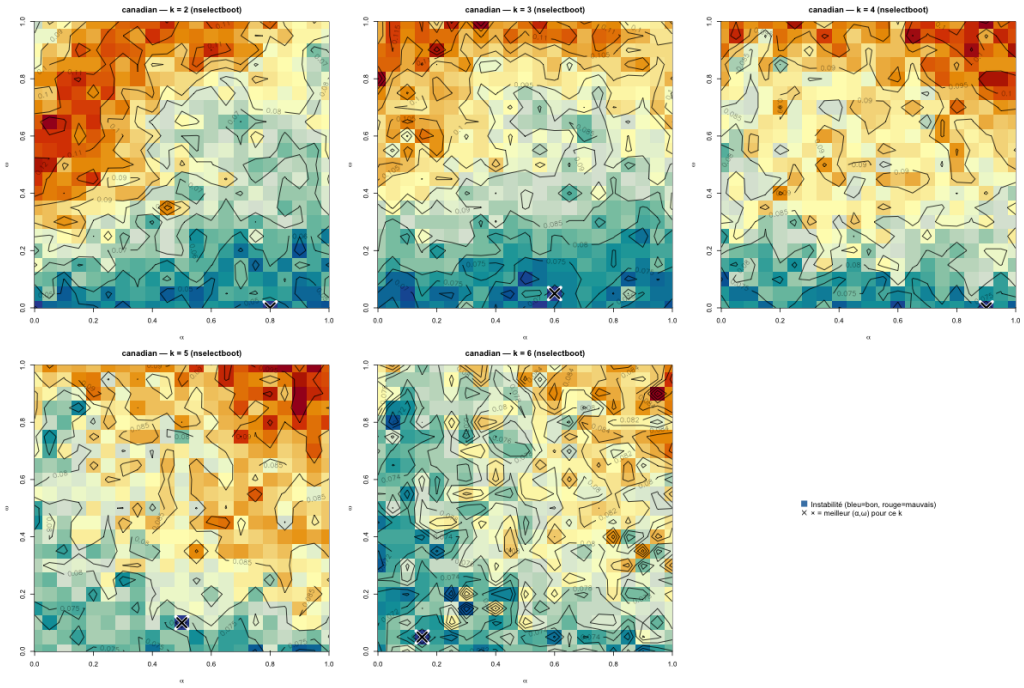

11.5 Autres datasets

Les figures `stabilite_heatmap_*.png` et `nselectboot_heatmap_*.png` sont dans `figures/` pour les 4 datasets. Grille identique : 21×21 (pas 0.05).

12 Paramètres des expériences

- **Stabilité** : grille $\alpha, \omega \in \{0, 0.05, \ldots, 1\}$ (21×21), $k \in \{2, \ldots, 6\}$, $B = 150$, sous-échantillon 80 %.
- **nselectboot** : mêmes paramètres (grille 21×21, $B = 150$, $k \in \{2, \ldots, 6\}$).

13 Conclusion

La stabilité est un critère simple et sans labels. Mais elle choisit toujours $k = 2$, ce qui pose problème sur Canadian, AEMET et Tecator. nselectboot, en testant plusieurs (α, ω), récupère $k = 4$ sur Canadian et AEMET, et $k = 3$ sur Tecator. Une piste : combiner les deux méthodes ou faire voter plusieurs critères.

En résumé pour les correcteurs :

- Problème : choisir k, α, ω sans labels.
- Méthode 1 (stabilité) : maximise l'accord quand on enlève 20 % des données. Résultat : $k = 2$ partout.
- Méthode 2 (nselectboot) : minimise l'instabilité sur une grille. Résultat : $k = 4$ sur Canadian et AEMET (correct), $k = 2$ sur Growth (correct), $k = 3$ sur Tecator (correct).
- Conclusion : la stabilité a un biais vers les petits k. nselectboot fait mieux quand on regarde toute la grille.

Références

— Dudoit, S., Fridlyand, J. (2002). A prediction-based resampling method for estimating the number of clusters. *Genome Biology*, 3(7), research0036.

— Fang, Y., Wang, J. (2012). Selection of the number of clusters via the bootstrap method. *Computational Statistics and Data Analysis*, 56(3), 468–477.

— Wang, J. (2010). Consistent selection of the number of clusters via crossvalidation. *Biometrika*, 97(4), 893–904.