Expérience 01 — Instabilité bootstrap et choix de k (Fang & Wang)

Pierre Chambet

Mars 2026

Résumé

On veut choisir k (nombre de clusters) et les paramètres de distance (α, ω) sans labels. Ce rapport se concentre sur une méthode de la littérature : **nselectboot** (Fang & Wang, 2012), implémentée dans R (`fpc::nselectboot`), qui minimise une **instabilité** mesurée par bootstrap. Un ancien protocole de « stabilité » ad hoc (sans article de référence) a été retiré pour clarifier le message. On teste une grille 21×21 en (α, ω) sur quatre jeux de données ; les labels ne servent qu'à évaluer l'ARI une fois k choisi.

Table des matières

1 Objectif de l'expérience 1 **3**

2 Le problème en une phrase **3**

3 Les trois paramètres et les données **3**

4 nselectboot (Fang & Wang, 2012) **3**
- 4.1 Idée . . . 3
- 4.2 PAM . . . 3
- 4.3 Protocole (résumé) . . . 3
- 4.4 Résumé sur la grille . . . 4

5 Résultats : triplets retenus pour l'évaluation (nselectboot) **4**

6 Matrices de confusion (nselectboot) **4**

7 Heatmaps d'instabilité (nselectboot) **5**
- 7.1 Canadian . . . 5
- 7.2 AEMET . . . 6
- 7.3 Growth . . . 6
- 7.4 Tecator . . . 7

8 Paramètres des expériences **7**

9 Conclusion **7**

1 Objectif de l'expérience 1

On veut choisir trois quantités **sans utiliser les labels pour le choix** :
— k : nombre de clusters.
— α : pondération entre distance sur les courbes (niveau) et sur les dérivées (forme).
— ω : pondération entre partie fonctionnelle et partie vectorielle (Z).

La méthode retenue est **nselectboot** : pour chaque couple (α, ω) de la grille, on estime un k_{opt} qui minimise l'instabilité bootstrap. On obtient une carte $(\alpha, \omega) \mapsto k_{\text{opt}}$ et des heatmaps d'instabilité par k.

Pourquoi une grille en (α, ω) ? Parce que α et ω changent la matrice de distances $D_w(\alpha, \omega)$ et donc le clustering. Les heatmaps montrent l'instabilité par (α, ω) et k : **bleu = faible instabilité (bon)**, **rouge = forte (mauvais)**.

2 Le problème en une phrase

Pour du clustering, il faut fixer k et la distance. Sans vérité terrain pour choisir, on utilise un critère documenté (instabilité bootstrap).

3 Les trois paramètres et les données

— k : nombre de clusters testé dans $\{2, \ldots, 6\}$.
— α : mélange D_0 (courbes) / D_1 (dérivées).
— ω : mélange distance fonctionnelle / distance sur Z.

Quatre jeux de données (labels uniquement pour **évaluer** après coup) : Canadian, AEMET, Growth, Tecator. Les k_{vrai} utilisés dans les tableaux viennent des scripts `src/00_preprocess*.R` : Canadian (`CanadianWeather$region`), Growth (garçons/filles), AEMET et Tecator via des règles définies dans le projet (géographie / seuils sur la matière grasse) — ce ne sont pas des vérités « absolues », mais des références pour comparer les partitions.

4 nselectboot (Fang & Wang, 2012)

4.1 Idée

On **minimise l'instabilité** : à chaque répétition bootstrap, on mesure à quel point deux partitions (obtenues sur deux échantillons bootstrap) se contredisent. Le k qui minimise cette instabilité moyenne est retenu pour le couple (α, ω) fixé.

4.2 PAM

PAM (k-medoids) travaille sur une matrice de distances ; les centres sont des **médoïdes** (individus réels), ce qui limite l'influence des outliers par rapport à des moyennes (k-means).

4.3 Protocole (résumé)

Pour chaque (α, ω) de la grille (21×21, pas 0.05), avec $B = 150$:

1. Construire $D_w(\alpha, \omega)$ (même pipeline que le reste du projet : lissage, FPCA, distances).
2. Pour chaque $k \in \{2, \ldots, 6\}$, `fpc::nselectboot` tire deux échantillons bootstrap d'indices, clusterise avec PAM sur les sous-matrices, complète les partitions sur tous les individus (classification croisée), puis agrège une mesure d'instabilité (voir code du package).
3. $k_{\text{opt}} = \arg\min_k \widehat{\text{instabilité}}(k)$.

Les fichiers `nselectboot_*.csv` et les figures `nselectboot_heatmap_*.png` synthétisent les résultats.

4.4 Résumé sur la grille

En regardant la médiane des k_{opt} sur les 441 couples : Canadian $\to$ 4, AEMET $\to$ 4, Growth $\to$ 2, Tecator $\to$ 3, cohérent avec les k_{vrai} retenus pour l'évaluation (sauf conventions sur AEMET/Tecator).

5 Résultats : triplets retenus pour l'évaluation (nselectboot)

Pour les matrices de confusion, on prend le premier couple (α, ω) de la grille tel que $k_{\text{opt}} = k_{\text{vrai}}$ (sinon le plus proche), comme dans `generate_confusion_nselectboot.R`.

Dataset	k_{vrai}	k	(α, ω)	ARI
Canadian	4	4	$(0.25, 0.15)$	0.62
AEMET	4	4	$(0.35, 0.20)$	0.39
Growth	2	2	$(0.10, 0.05)$	0.42
Tecator	3	3	$(0.75, 0.10)$	0.58

TABLE 1 – Partition évaluée avec les labels (ARI).

6 Matrices de confusion (nselectboot)

Lignes = vraies classes. Colonnes = clusters prédits.

Canadian ($k = 4$, ARI 0.62)

	C1	C2	C3	C4
Arctic	0	0	3	0
Atlantic	15	0	0	0
Continental	1	6	5	0
Pacific	0	4	0	1

AEMET ($k = 4$, ARI 0.39)

	C1	C2	C3	C4
Atlantique	9	4	0	0
Continental	2	19	0	0
Mediterranee	0	3	15	0
Sud	0	3	10	8

Growth ($k = 2$, ARI 0.42)

	C1	C2
Fille	6	48
Garcon	29	10

Tecator ($k = 3$, ARI 0.58)

	C1	C2	C3
Maigre	19	0	93
Moyen	39	23	0
Gras	2	39	0

7 Heatmaps d'instabilité (nselectboot)

Pour chaque k, l'instabilité en fonction de (α, ω). Bleu = bas = bon. $\times$ = meilleur (α, ω) pour ce k (voir script d'analyse).

7.1 Canadian

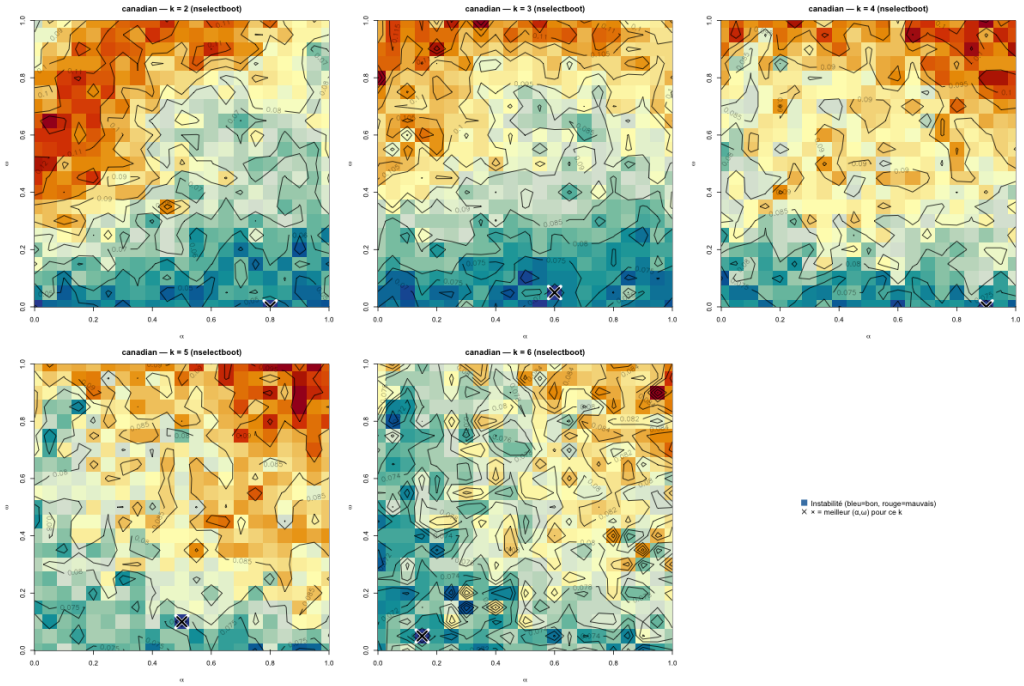

7.2 AEMET

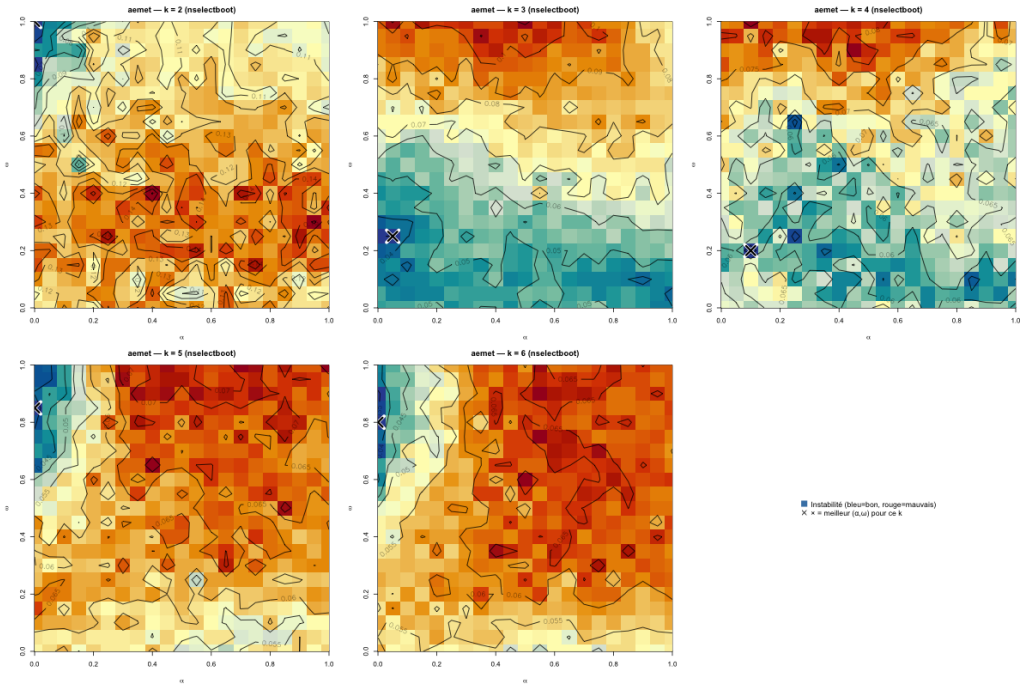

7.3 Growth

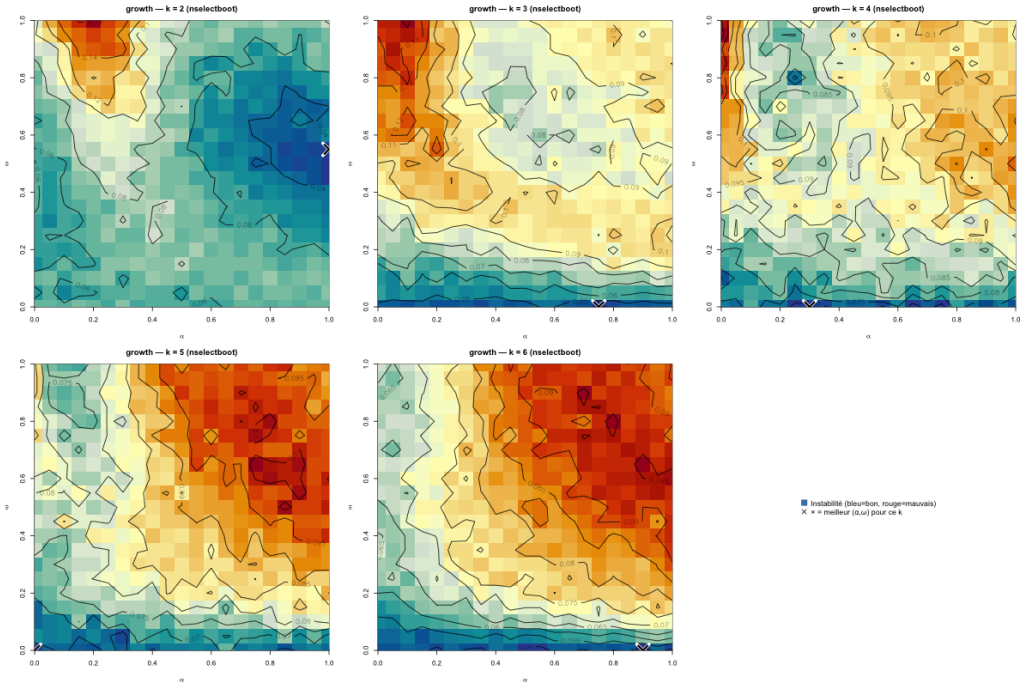

7.4 Tecator

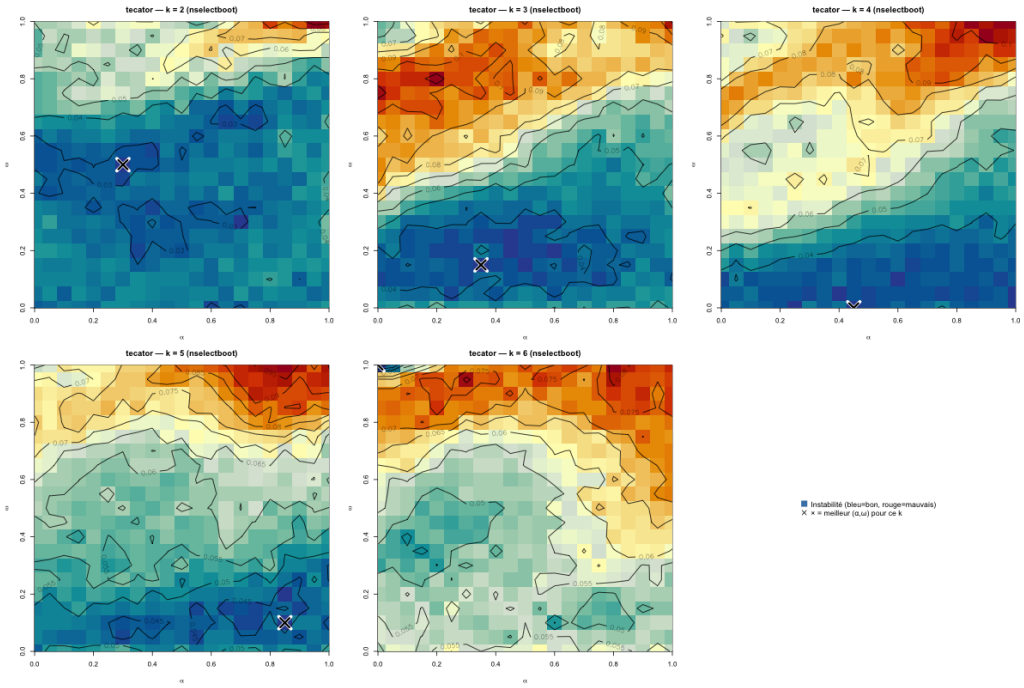

8 Paramètres des expériences

— Grille $\alpha, \omega \in \{0, 0.05, \ldots, 1\}$ (21×21).
— $k \in \{2, \ldots, 6\}$, $B = 150$ répétitions bootstrap pour nselectboot.
— Même prétraitement que le pipeline principal (`src/01_lissage.R`, `02_fpca.R`, `03_distances.R`).

9 Conclusion

L'expérience 1 s'appuie sur une méthode publiée (instabilité bootstrap, Fang & Wang) pour choisir k à (α, ω) fixé, puis explore toute la grille. Les labels servent uniquement à l'ARI et aux matrices de confusion, pas au choix de (k, α, ω).

Références :

— Fang, Y., Wang, J. (2012). Selection of the number of clusters via the bootstrap method. *Computational Statistics and Data Analysis*, 56(3), 468–477.